

MDR 573- - Lista de questões - testes não paramétricos

AUTHOR

Bruno F. Guedes

PUBLISHED

April 30, 2024

```
#load packages
suppressPackageStartupMessages(library(ggplot2))
suppressPackageStartupMessages(library(dplyr))
suppressPackageStartupMessages(library(tidyr))
suppressPackageStartupMessages(library(purrr))
```

Questão 1:

Questão 1 / 10

A mediana NÃO é equivalente a:

- A 2-quantil
- B 2º quartil
- C 50º percentil
- D 5º decil
- E 50º postil

Resposta

A mediana é um quantil. Tanto faz em quantas partes dividimos o todo, o importante é ser um quantil que separa a metade dos pontos para cada lado, todos os quantis que equivalem a um corte de 50% estão certos. "Postil" é uma palavra que nem consegui localizar na internet, e, se corresponder a um posto específico, certamente não tem nenhuma garantia de um postil de 50 corresponder à mediana. Por exemplo, se os nossos dados são 1:50, o postil 50 equivale a um percentil de 100%, bem diferente da mediana. Um posto de 50 so corresponderia à mediana se tivessemos 100 pontos.

alternativa E

Questão 2:

Um pesquisador da área médica deseja estudar o efeito de um novo tratamento em pacientes com determinada doença em relação a dois tratamentos convencionais. Em cada um dos três tratamentos foram alocados aleatoriamente dez pacientes distintos. A variável de desfecho com distribuição normal é o número de dias sem fortes desconfortos no período de um ano de tratamento. O teste estatístico mais adequado para o estudo é:

- A ANOVA de Welch
- B U de Mann-Whitney
- C H de Kruskal-Wallis
- D Q de Friedman
- E W de Wilcoxon

Resposta

Comparação entre-grupos com 3 ou mais grupos com variável desfecho normal - o teste a ser utilizado é o ANOVA de Welch. O H de Kruskal-Wallis também poderia ser usado aqui, mas não é necessário usar teste não-paramétrico aqui, uma vez que os dados são normais.

Alternativa A

Questão 3:

Um pesquisador da área médica deseja estudar o efeito de um novo tratamento em pacientes com determinada doença em relação ao tratamento convencional. Dez pacientes foram alocados aleatoriamente ao tratamento novo e outros dez pacientes foram alocados ao tratamento convencional. A variável de desfecho com distribuição normal é o número de dias sem fortes desconfortos no período de um ano de tratamento. O teste estatístico mais adequado para o estudo é:

- A z
- B t
- C U
- D H
- E Q
- F W

Resposta

Aqui temos dois grupos independentes, nos quais comparamos variável de distribuição normal. Teste t é o teste de escolha.

Alternativa B

Questão 4:

Os testes estatísticos de associação mais adequados entre duas variáveis nominais, duas ordinais e duas intervalares são, respectivamente:

- A Qui-quadrado de Pearson, qui-quadrado de Pearson e qui-quadrado de Pearson
- B Qui-quadrado de Pearson, qui-quadrado de Pearson e correlação de Pearson
- C Correlação de Pearson, correlação de Spearman e qui-quadrado de Pearson
- D Correlação de Spearman, qui-quadrado de Pearson e correlação de Pearson
- E Qui-quadrado de Pearson, correlação de Spearman e correlação de Pearson

Resposta

Aqui acho que é ligeiramente pegadinha. Porque a palavra usada é "associação". Para testar associação entre duas variáveis nominais, usamos Qui quadrado. Para duas variáveis ordinais, embora existam testes de correlação, o teste ideal para testar "associação" segue sendo o Qui quadrado. Pra avaliar

variáveis intervalares, usando correlação de Pearson. Então fico em dúvida entre o pedantismo de dizer que "associação é associação", para isso somente qui-quadrado, ou a interpretação mais relaxada do que é associação, que levaria à resposta mais natural com a alternativa E. Uma coisa que ajuda é que, se a gente for muito criterioso com a necessidade de "associação" no sentido de dependência como nas variáveis categóricas, não teria nenhum teste razoável para as variáveis intervalares, então vamos de:

Alternativa E

Questão 5:

Um pesquisador da área médica deseja estudar o efeito de um novo tratamento em pacientes com determinada doença em relação ao tratamento convencional. Cada paciente - de dez pacientes - foi submetido aos dois tratamentos. A variável de desfecho do estudo com distribuição normal é o número de dias sem fortes desconfortos no período de um ano de tratamento. O teste estatístico mais adequado para o estudo é:

- A t relacionado
- B Qui-quadrado
- C W
- D U

Resposta

Para duas amostras de VD com distribuição normal, pareadas (análise intra-grupos), o teste de escolha é o teste t pareado ("relacionado no enunciado")

Alternativa A

Questão 6

Um pesquisador da área médica deseja estudar o efeito de um novo tratamento em pacientes com determinada doença em relação a dois tratamentos convencionais. Em cada um dos três tratamentos foram alocados aleatoriamente seis pacientes distintos. A variável de desfecho com distribuição desconhecida e simétrica em cada tratamento é o número de dias sem fortes desconfortos no período de um ano de tratamento. O teste estatístico mais adequado para o estudo é:

- A t independente
- B Qui-quadrado
- C H
- D ANOVA independente

Resposta

Aqui acho que é o caso que o senso comum leva a responder *H de Kruskal-Wallis*, porque é o teste não paramétrico de escolha para comparar 3 distribuições independentes, e a literatura diz ser especialmente válido usar esse teste quando os pressupostos de testes paramétricos (normalidade para

anova) não são atingidos. Testes baseados em postos como o de Mann-Whitney e K-W ainda tem alguns pressupostos, como a simetria. Mas nesse caso esses pressupostos estão atingidos. Então parece um bom caso para KW. Fico só na dúvida porque na aula claramente demonizaram todos os testes não-paramétricos, então não sei se não estão testando a gente aqui e querem que a gente coloque ANOVA mesmo assim. Fui de KW, pq esse caso tem todos os pressupostos teóricos para usar o teste, seja ele o melhor na teoria dos profs ou não. Tentei fazer uns testes com distribuição triangular, que é simétrica mas não é normal:

```
# criar função que simula distribuição triangular

generate_triangle <-
  \(center, n, one_tail_range) {
    triang_data <- \( ) {
      runif(n,
            min = center/2 - one_tail_range,
            max = center/2 + one_tail_range)
    }
    output <- triang_data() + triang_data()
    output
  }

# criar distribuições triangulares

set.seed(1)

triang_1 <-
  generate_triangle(center = 0,
                    n = 1e6,
                    one_tail_range = 1)

triang_2 <-
  generate_triangle(center = 1,
                    n = 1e6,
                    one_tail_range = 1)

triang_3 <-
  generate_triangle(center = 2,
                    n = 1e6,
                    one_tail_range = 1)

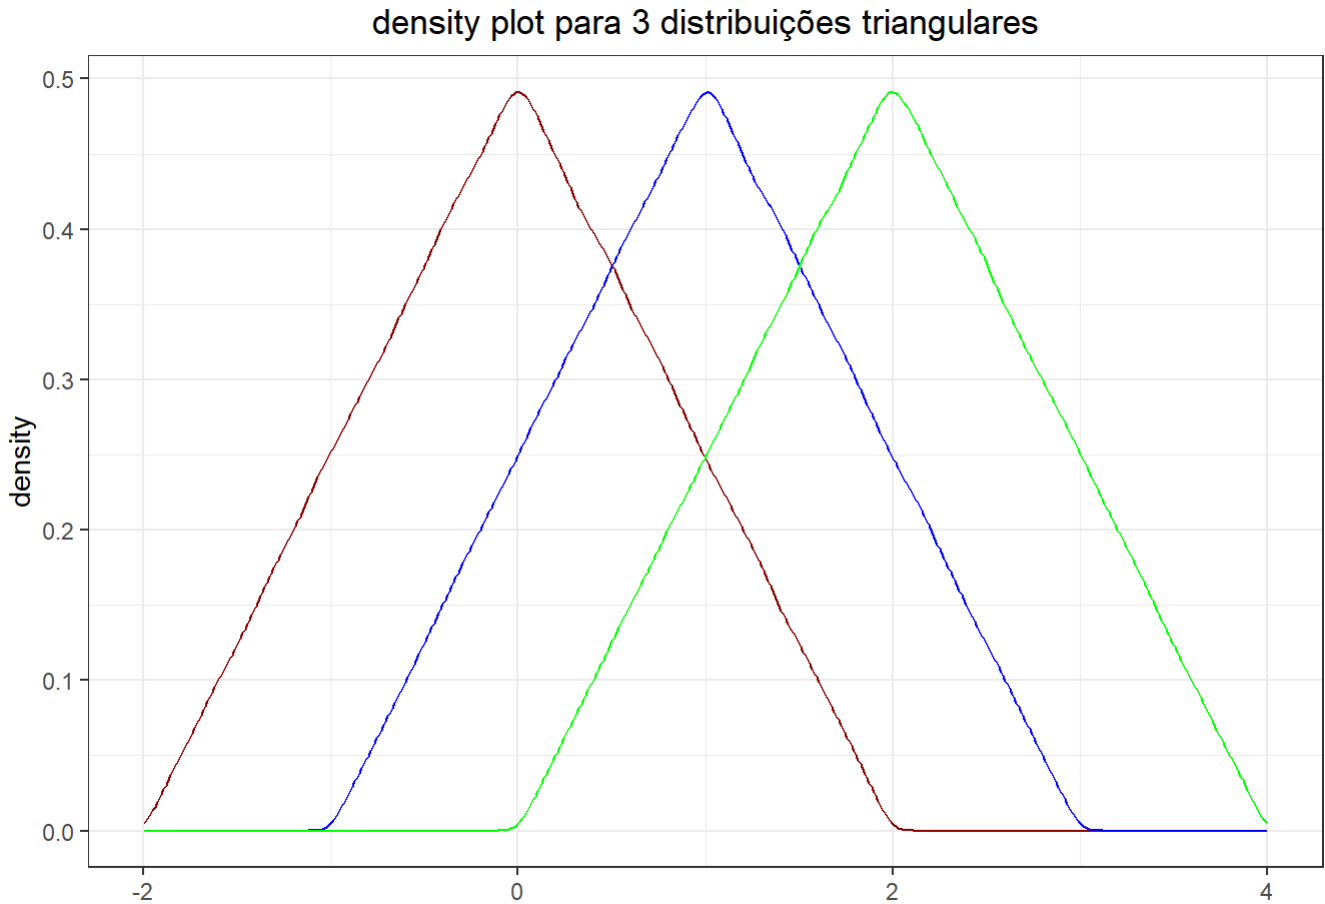
#plotar as distribuições triangulares
ggplot2::ggplot() +
  geom_density(data = data.frame(triang_1 = triang_1),
               aes(x = triang_1,
                   color = 'dark red')) +

  geom_density(data = data.frame(triang_2 = triang_2),
               aes(x = triang_2,
                   color = 'blue')) +

  geom_density(data = data.frame(triang_3 = triang_3),
               aes(x = triang_3,
                   color = 'green')) +

  theme_bw() +
  xlab("") +
```

```
ggtitle('density plot para 3 distribuições triangulares') +  
theme(plot.title = element_text(hjust = 0.5))
```



```
# criar data.frames com amostras desses triangulos  
  
# função que tira subamostra com 6 elementos de uma distribuição  
six_elements <-  
  \(\x) {  
    sample(x,  
      size = 6,  
      replace = FALSE)  
  }  
  
# função que cria data.frame a partir das 3 distribuições  
  
set.seed(1)  
  
create_data.frame <-  
  \(\list_of_distributions){  
    lapply(list_of_distributions,  
      \(\x) six_elements(x)) |>  
    as.data.frame() |>  
    setNames(c("grupo_1", "grupo_2", "grupo_3")) |>  
    tidyr::pivot_longer(cols = everything(),  
      names_to = "grupo",  
      values_to = "valor")  
  }
```

```
# criar 1000 data.frames
list_of_data.frames <-
  lapply(1:1000,
    \(x) create_data.frame(list(triang_1,
                                triang_2,
                                triang_3)))

## criar as funções que rodam os testes
## anova
teste_aov <-
  \(x) {
    aov(data = x,
        formula = valor ~ grupo)
  }

teste_kw <-
  \(x) {
    kruskal.test(formula = valor ~ grupo,
                  data = x)
  }

# aplicar os testes nas 1000 data.frames

list_of_tests <-
  lapply(
    list(
      teste_aov,
      teste_kw
    ),
    \(x) lapply(list_of_data.frames,
                \(y) x(y)
                )
  )

# obter os valores p dos testes

list_of_summaries <-
  list(aov = lapply(list_of_tests[[1]],
                    \(x) summary(x)[[1]][["grupo", "Pr(>F)"]]),
        kw = lapply(list_of_tests[[2]],
                    \(x) x[["p.value"]])
  )

data.frame_of_summaries <-
  list_of_summaries |>
  lapply(unlist) |>
  as.data.frame()
```

O bloco acima simulou 1000 data.frames criadas a partir de subamostras das distribuições triangulares. Abaixo vamos verificar como os dois testes se comportam:

```
# explorar os dados
## proporção de valores de  $p < 0.05$ 
data.frame_of_summaries |>
```


```
dplyr::summarise(across(everything(),  
  \ (x) mean(x < 0.05)))
```

```
  aov  kw  
1 0.937 0.9
```

Os dois rejeitam H0 de forma consistente, o aov um pouco melhor.

```
# plotar valores de p em cada um dos eixos  
library(ggplot2)  
  
data.frame_of_summaries |>  
  ggplot(aes(x = aov,  
    y = kw)) +  
  geom_point(alpha = 0.5) +  
  geom_vline(xintercept = 0.05,  
    color = "red",  
    linetype = "dashed") +  
  geom_hline(yintercept = 0.05,  
    color = "blue",  
    linetype = "dashed") +  
  ggtitle("p values for ANOVA(aov) x Kruskal-Wallis(kw)", subtitle = "dashed lines represent  
  theme_bw() +  
  theme(plot.title = element_text(hjust = 0.5),  
    plot.subtitle = element_text(hjust = 0.5))
```

p values for ANOVA(aov) x Kruskal-Wallis(kw)
dashed lines represent the 0.05 threshold



Da pra ver, pelo grafico acima, que é mais comum apenas kw falhar em rejeitar a H0 (quadrante superior esquerdo) do que apenas o aov (inferior direito), embora em varios casos ambos tenham falhado (superior direito). Então mudei minha resposta para D - ANOVA.

Alternativa D

Questão 6 - simulação bonus

Agora vamos tentar uma simulação semelhante, mas ao inves das distribuições triangulares, vamos usar distribuições irregulares:

```
# criando as distribuições irregulares e sua data.frame

set.seed(1)

two_normal_distrs_1 <-
  list(rnorm(n = 1e6, mean = 0, sd = 1),
       rnorm(n= 1e6, mean = 5, sd = 2))

two_normal_distrs_2 <-
  list(rnorm(n = 1e6, mean = 2, sd = 1),
       rnorm(n= 1e6, mean = 0, sd = 2))

two_normal_distrs_3 <-
  list(rnorm(n = 1e6, mean = 4, sd = 1),
       rnorm(n= 1e6, mean = 7, sd = 2))

distr_1 <- c(sample(two_normal_distrs_1[[1]], 1e5*6),
             sample(two_normal_distrs_1[[2]], 1e5*4))

distr_2 <- c(sample(two_normal_distrs_2[[1]], 1e5*7),
             sample(two_normal_distrs_2[[2]], 1e5*3))

distr_3 <- c(sample(two_normal_distrs_3[[1]], 1e5*5),
             sample(two_normal_distrs_3[[2]], 1e5*5))

data <-
  data.frame(distr_1, distr_2, distr_3) |>
  tidyr::pivot_longer(everything(),
                      names_to = "grupo",
                      values_to = 'valores')


ggplot2::ggplot() +
  geom_density(data = data,
              aes(x= valores,
                  color = grupo)) +
  scale_color_manual(values = c('distr_1' = 'red',
                                'distr_2' = 'blue',
                                'distr_3' = 'green'))+
  geom_vline(xintercept =
             mean(filter(data, grupo == 'distr_1') |> pull(valores)),
```



```

    linetype = 'dashed',
    color = 'red') +
  geom_vline(xintercept =
    mean(filter(data, grupo == 'distr_2') |> pull(valores)),
    linetype = 'dashed',
    color = 'blue') +
  geom_vline(xintercept =
    mean(filter(data, grupo == 'distr_3') |> pull(valores)),
    linetype = 'dashed',
    color = 'green') +
  theme_bw() +
  xlab("") +
  ggtitle('density plot para 3 distribuições irregulares') +
  theme(plot.title = element_text(hjust = 0.5))

```



```

# criar 1000 data.frames
list_of_data.frames <-
  lapply(1:1000,
    \(x) create_data.frame(list(distr_1,
                                distr_2,
                                distr_3)))

# aplicar os testes nas 1000 data.frames

list_of_tests <-
  lapply(

```

```

list(
  teste_aov,
  teste_kw
),
\ (x) lapply(list_of_data.frames,
             \ (y) x(y)
)
)
# obter os valores p dos testes

list_of_summaries <-
  list(aov = lapply(list_of_tests[[1]],
                    \ (x) summary(x)[[1]][ "grupo", "Pr(>F)"]),
        kw = lapply(list_of_tests[[2]],
                     \ (x) x[["p.value"]])
)

data.frame_of_summaries <-
  list_of_summaries |>
  lapply(unlist) |>
  as.data.frame()

# explorar os dados
## proporção de valores de p < 0.05
data.frame_of_summaries |>
  dplyr::summarise(across(everything(),
                          \ (x) mean(x < 0.05)))

```

```

      aov      kw
1 0.797 0.796

```


O desempenho aqui foi parecido

```

# plotar valores de p em cada um dos eixos
library(ggplot2)

data.frame_of_summaries |>
  ggplot(aes(x = aov,
             y = kw)) +
  geom_point(alpha = 0.5) +
  geom_vline(xintercept = 0.05,
            color = "red",
            linetype = "dashed") +
  geom_hline(yintercept = 0.05,
            color = "blue",
            linetype = "dashed") +
  ggtitle("p values for ANOVA(aov) x Kruskal-Wallis(kw)", subtitle = "dashed lines represent t
  theme_bw() +
  theme(plot.title = element_text(hjust = 0.5),
        plot.subtitle = element_text(hjust = 0.5))

```



Questão 7

Um pesquisador da área médica deseja estudar o efeito de um novo tratamento em pacientes com determinada doença em relação a dois tratamentos convencionais. Cada um dos dez pacientes foi submetido aos três tratamentos. A variável de desfecho do estudo com distribuição normal é o número de dias sem fortes desconfortos no período de um ano de tratamento. O teste estatístico mais adequado para o estudo é:

- A t pareado
- B Qui-quadrado
- C Q de Friedman
- D ANOVA relacionada

Resposta

O teste para variável contínua de distribuição normal, pareada (intra-participantes), com mais de 2 grupos, é o de ANOVA relacionada

Alternativa D

Questão 8

Um pesquisador da área médica deseja estudar o efeito de um novo tratamento em pacientes com determinada doença em relação a dois tratamentos convencionais. Cada um dos dez pacientes foi submetido aos três tratamentos. A variável de desfecho do estudo é ordinal com os níveis é A (0% a 25% de dias sem fortes desconfortos no período de um ano de tratamento), B (>25% a 50%), C (>50% a 75%) e D (>75% a 100%). O teste estatístico mais adequado para o estudo é:

- A t relacionado
- B Qui-quadrado de Pearson
- C Q de Friedman
- D ANOVA relacionada
- E W de Wilcoxon
- F H de Kruskal-Wallis

Resposta

Aqui, mais uma vez, da muita vontade de responder *Q de Friedman*, porque é o teste de escolha para medidas repetidas (intra-participantes), com n pequeno e variavel ordinal com pouquissimos niveis. Nunca sei se não é mais uma pegadinha pra testar a nossa fé nos testes paramétricos. Se tivermos fé, colocamos ANOVA relacionada. Eu acho que não tenho. E dessa vez fiquei com preguiça de fazer as simulações.

Alternativa C

Questão 9

A VD de teste U de Mann-Whitney NÃO pode ser:

- A Nominal
- B Ordinal
- C Intervalar
- D Razão
- E Contagem

Resposta

Tudo que pode ser ordenado pode entrar num teste de MU. Então apenas o que não é ordenavel (variavel nominal) é impossivel de ser usado num teste de mann whitney.

Alternativa A

Questão 10

A VD de teste W de Wilcoxon tem que ser:

- A Nominal
- B Ordinal
- C Intervalar

Resposta

Da aula:

O teste W de Wilcoxon testa a hipótese nula de igualdade das médias populacionais da VD quantitativa em duas condições dependentes. É, portanto, correspondente ao teste t relacionado.

Conover (1999) sumariza as suposições: a distribuição das diferenças deve ser simétrica. as diferenças devem ser independentes entre si. todas as diferenças precisam ter a mesma média. a medida das diferenças deve ser pelo menos intervalar.

A VD não pode ser, conseqüentemente, ordinal (vide a tabela de Conover, 1999).

Achei muito confuso, porque o senso comum leva a crer que testes de postos são adequados para variáveis ordinais mas GPT deu uma explicação consistente. Resumindo muito (e talvez mal), o teste W para amostras pareadas precisa primeiro calcular as diferenças entre pares, e depois cria um rank das diferenças. Ou seja, embora seja um teste de postos, os postos surgem em uma etapa intermediária, e é necessário ter as distâncias intervalares para criar os postos, por isso a necessidade de ter variáveis intervalares.

Do GPT-4:

O requisito de que a variável de resultado seja "pelo menos de intervalo, não ordinal" no contexto do teste W de Wilcoxon para dados emparelhados (também conhecido como teste de sinais e postos de Wilcoxon) pode parecer um pouco confuso, dada sua natureza como um teste não paramétrico baseado em ranqueamento. Aqui está como isso se encaixa na metodologia do teste e suas premissas:

Natureza dos Testes Baseados em Ranks: Testes baseados em ranks, incluindo o teste de sinais e postos de Wilcoxon, geralmente transformam os dados em ranks, mitigando assim os efeitos de outliers e não-normalidade. Isso os torna adequados para dados não paramétricos que não assumem uma distribuição específica, como a distribuição normal, frequentemente assumida em testes paramétricos.

Manuseio das Diferenças Emparelhadas: O teste de sinais e postos de Wilcoxon lida especificamente com diferenças emparelhadas. Ele ranqueia essas diferenças, independentemente de seu sinal, e então usa esses ranks para avaliar se a mediana das diferenças é significativamente diferente de zero. O ponto crítico aqui é que o teste calcula diferenças entre pares e depois ranqueia essas diferenças.

Requisito para Dados de Intervalo: Embora seja verdade que testes baseados em ranks tipicamente não precisem de dados de intervalo e possam operar com dados ordinais, a operação de calcular diferenças (usada no teste de sinais e postos de Wilcoxon) pressupõe que essas diferenças sejam significativas. Isso não é garantido em dados ordinais. Por exemplo, se você tem

categorias ordinais como "ruim", "regular", "bom" e "excelente", a diferença entre "ruim" e "regular" pode não ser equivalente à diferença entre "bom" e "excelente". Portanto, para que o teste calcule e interprete essas diferenças com precisão, os dados precisam estar pelo menos em uma escala de intervalo, onde a diferença entre quaisquer dois pontos é consistentemente significativa.

Aplicabilidade a Dados de Intervalo: Ao exigir que os dados estejam pelo menos em uma escala de intervalo, o teste garante que operações como a subtração, usadas no cálculo das diferenças, sejam válidas e consistentes. Isso permite um ranqueamento significativo dessas diferenças e um teste válido para inferência estatística sobre a tendência central das diferenças.

Alternativa C